

ПРОЕКТНАЯ РАБОТА

по прикладному статистическому анализу

на тему

*«Классификация регионов Российской Федерации на
основе показателей раскрываемости преступлений»*

Выполнили:

Есина Анастасия Артёмовна,

Попова Александра Константиновна

Москва, 2026

Содержание

Цели и гипотезы исследования.....	3
Линейный дискриминантный анализ	4
Построение деревьев классификации.....	11
Декомпозиция смеси распределений.....	19
Приложения.....	25

1. Цели и гипотезы исследования

В рамках дисциплины «Первичная обработка и представление статистических данных» нами была выполнена модульная работа №2 «Классификация регионов Российской Федерации на основе показателей раскрываемости преступлений».

Целью нашего исследования является построение классификационных моделей для отнесения регионов к одному из трех ранее выделенных кластеров на основе показателей раскрываемости.

В ходе проведения работы мы использовали выборку (см. Приложение 1), состоящую из 72 наблюдений (субъектов РФ) и 6 переменных («Принадлежность к кластеру»; «Общая раскрываемость, %»; «Раскрываемость тяжких преступлений, %»; «Раскрываемость коррупционных дел, %»; «Раскрываемость преступлений в сфере информационно-коммуникационных технологий, %»; «Раскрываемость наркопреступлений, %»)

В предыдущей работе данные были разделены методом k-средних на три кластера: Кластер 1. «Регионы-лидеры» (самые большие показатели по каждой раскрываемости), Кластер 2. «Регионы-лидеры по раскрываемости коррупционных дел», Кластер 3. «Регионы с минимальной раскрываемостью коррупционных дел».

В качестве целевой переменной для дискриминантного анализа и деревьев решений выступает категориальная переменная «Принадлежность к кластеру», полученная в результате кластеризации методом k-средних в предыдущей работе.

Гипотезы:

H₁: Существует региональная дифференциация по показателям раскрываемости.

H₂: Дискриминантный анализ позволяет с высокой точностью классифицировать регионы по кластерам на основе показателей раскрываемости.

H₃: Деревья решений обеспечивают более высокую интерпретируемость по сравнению с дискриминантным анализом.

2. Линейный дискриминантный анализ

2.1 Выделение наблюдений, подлежащих дискриминации

Выделим три региона, которые резко выделяются и наиболее удалены от центров кластеров. Для этого определим центры кластеров (средние значения для каждой переменной) и рассчитаем евклидово расстояние. Евклидово расстояние определяется по формуле:

$$d_i = \sqrt{(x_{i1} - \bar{x}_{k1})^2 + (x_{i2} - \bar{x}_{k2})^2 + (x_{i3} - \bar{x}_{k3})^2 + (x_{i4} - \bar{x}_{k4})^2 + (x_{i5} - \bar{x}_{k5})^2},$$

где i - порядковый номер региона, k - порядковый номер кластера, $x_{i1}, x_{i2}, \dots, x_{i5}$ - значения пяти показателей для региона i , $\bar{x}_{k1}, \bar{x}_{k2}, \dots, \bar{x}_{k5}$ - центры кластера k .

Наиболее удалёнными от центров кластеров будут являться регионы с максимальным евклидовым расстоянием. Такими оказались г. Санкт-Петербург (значение евклидового расстояния 61,44), Республика Башкортостан (значение евклидового расстояния 61,21), Удмуртская Республика (значение евклидового расстояния 61,16).

2.2 Проведение дискриминантного анализа

В программном обеспечении Microsoft Excel при помощи надстройки «Real Statistics Resource Pack» был произведён дискриминантный анализ, в ходе которого были получены таблицы Means (рис. 1), Coefficients (рис.2), Summary Table (рис. 3), Categorization of Training Data (см. Приложение 2), получено значение $p\text{-value} = 0,05701328$. Также были дополнительно построены таблицы Eigenvalues (рис. 4) и Wilks' Lambda (рис. 5) при помощи языка программирования Python.

Means					
1	55,5266667	40,69	95,0933333	21,4366667	58,6666667
2	54,9846154	41,5846154	96,7730769	21,7923077	57,6923077
3	55,7461538	43,7923077	87,3692308	21,1	61,8384615

Рисунок 1. Таблица средних значений исходных показателей по каждому кластеру Means

Coefficients							
		x1	x2	x3	x4	x5	
1	-153,51936	0,26866696	-0,0509347	2,94668263	0,04688603	0,22121786	
2	-158,19386	0,19762823	-0,0074689	3,01595902	0,10099229	0,20396689	
3	-132,59993	0,2985312	0,01997345	2,66953363	-0,0606092	0,25432348	

Рисунок 2. Таблица коэффициентов уравнений дискриминантных функций Coefficients

Summary Table					
		correct	total	% correct	% missed
1		8	30	0,26666667	0,73333333
2		19	26	0,73076923	0,26923077
3		9	13	0,69230769	0,30769231
		36	69	0,52173913	0,47826087

Рисунок 3. Таблица качества классификации выборки Summary Table

ТАБЛИЦА EIGENVALUES				
Function	Eigenvalue	% of Variance	Cumulative %	Canonical Corr.
1	0.9577	95.77	95.77	0.6994
2	0.0423	4.23	100.00	0.2015

Рисунок 4. Таблица Eigenvalues

СВОДНАЯ ТАБЛИЦА WILKS' LAMBDA					
Пары групп	λ Wilks	F-стат.	df1, df2	p-value	
Кластер 1 vs Кластер 2	0.9379	0.6620	(5,50)	0.6539	
Кластер 1 vs Кластер 3	0.6831	3.4336	(5,37)	0.0120	
Кластер 2 vs Кластер 3	0.4912	6.8371	(5,33)	0.0002	

Рисунок 5. Таблица Wilks' Lambda

2.3 Выражения для дискриминантной функции

Общий вид дискриминантной функции:

$$D_k = c_k + a_{1k} \cdot X_1 + a_{2k} \cdot X_2 + a_{3k} \cdot X_3 + a_{4k} \cdot X_4 + a_{5k} \cdot X_5$$

где k – порядковый номер кластера, c_k - константа, a_{jk} - коэффициент при j-м показателе для кластера k, X_1 , X_2 , X_3 , X_4 , X_5 - общая раскрываемость (%),

раскрываемость тяжких преступлений (%), раскрываемость коррупционных дел (%), раскрываемость преступлений в сфере ИКТ (%) и раскрываемость наркопреступлений (%) соответственно. Путём подставления в формулу коэффициентов из таблицы Coefficients (рис. 2) получились три выражения для дискриминантных функций:

$$D1 = -153,5193582 + 0,268666956X_1 - 0,050934696X_2 + 2,946682633X_3 + 0,046886031X_4 + 0,221217863X_5$$

$$D2 = -158,1938649 + 0,197628228X_1 - 0,007468926X_2 + 3,015959024X_3 + 0,100992291X_4 + 0,203966889X_5$$

$$D3 = -132,5999336 + 0,298531201X_1 + 0,019973453X_2 + 2,669533629X_3 - 0,060609239X_4 + 0,254323478X_5$$

2.4 Оценка значимости дискриминантной функции по коэффициенту Уилкса

Для проверки статистической значимости полученных дискриминантных функций использовался коэффициент Уилкса λ . Результаты расчетов представлены на рис. 6.

Уилкса	0,64877725	p-value	0,05701328
X^2	27,6906137		
df	10		

Рисунок 6. Результаты расчётов для проверки значимости дискриминантной функции

$\lambda = 0,64877725$. Это значение ближе к единице, чем к нулю. Доля необъясненной дисперсии составляет 64,88%, а объясненной: $100\% - 64,88\% = 35,12\%$. Иными словами, дискриминантные функции умеренно разделяют группы. Полученное значение p-value (0,057) находится на границе статистической значимости ($0,057 \approx 0,05$), что может указывать на умеренную способность модели различать кластеры. Для повышения качества классификации может потребоваться увеличение выборки или включение дополнительных переменных.

2.5 Определение относительного вклада каждой переменной в формирование классов

Для переменной X_3 (раскрываемость коррупционных преступлений) нестандартизированные коэффициенты, полученные в результате дискриминантного анализа (см. таблицу Coefficients рис. 2), являются максимальными во всех трех функциях (для первой функции 2,95; для второй функции 3,02; для третьей функции 2,67). Переменная вносит очень высокий вклад в формирование кластеров и является главным фактором разделения.

Для переменной X_1 (общая раскрываемость) коэффициенты являются умеренными положительными (0,27; 0,20; 0,30). Переменная вносит средний вклад в формирование кластеров.

Для переменной X_5 (раскрываемость наркопреступлений) коэффициенты также являются умеренными положительными (0,22; 0,20; 0,25), схожие с коэффициентами X_1 , вклад переменной в формирование кластеров средний.

Для переменной X_4 (раскрываемость дел в сфере ИКТ) коэффициенты являются небольшими (для первой функции 0,05; для второй функции 0,10), в функции D_3 коэффициент отрицательный (-0,06). Переменная вносит низкий вклад в формирование кластеров.

Для переменной X_2 (раскрываемость тяжких преступлений) коэффициенты близки к нулю (-0,05; -0,01; 0,02). Вклад переменной очень низкий, раскрываемость тяжких преступлений почти не влияет на формирование кластеров. Таким образом, ключевым классификационным признаком является раскрываемость коррупционных дел, что согласуется с ранее выделенной структурой кластеров.

2.6 Определение средних значений дискриминантной функции по группам

Для определения средних значений дискриминантных функций по группам (центроидов) в выражения для дискриминантных функций, полученных ранее, подставим средние значения исходных показателей по каждому кластеру из таблицы Means (рис. 1). Результаты расчётов приведены ниже (рис. 7).

	кластер 1	кластер2	кластер3
D1	153,519358	158,07896	131,345706
D2	153,404454	158,193865	130,742023
D3	152,265131	156,335954	132,599934

Рисунок 7. Значения центроидов

Полученные центроиды представляют собой средние значения линейных классификационных функций для каждого кластера. Результаты показывают, что наибольшие различия наблюдаются между кластером 3 и остальными кластерами (разница составляет около 20 единиц по всем функциям). Кластеры 1 и 2 расположены ближе друг к другу, что свидетельствует об их относительной схожести по классификационным признакам.

2.7 Классификация объектов и вероятности, с которыми эти объекты входят в эти группы

Регионы, выбранные изначально для дискриминации - г. Санкт-Петербург, Республика Башкортостан, Удмуртская Республика. Порядковые номера кластеров, в которые были отнесены классифицируемые объекты, и вероятности, с которыми объекты входят в эти кластеры, можно найти в таблице Categorization of Training Data, фрагмент которой представлен на рис. 8.

	1	2	3	category
г. Санкт-Петербург	0,3816033	0,58063899	0,03775772	2
Республика Башкортостан	0,2791508	0,71056379	0,01028541	2
Удмуртская Республика	0,35956217	0,60684961	0,03358822	2

Рисунок 8. Классификация объектов и вероятность их вхождения в определённый кластер

Как мы видим, все три региона были отнесены к кластеру 2 - «Регионы-лидеры по раскрываемости коррупционных дел». Для г. Санкт-Петербург вероятность вхождения в кластер составляет 58,06%, для Республики Башкортостан - 71,06%, для Удмуртской Республики - 60,68%. При кластеризации методом k-средних эти регионы также были распределены во второй кластер.

Таким образом, дискриминантный анализ подтвердил принадлежность всех трех регионов к кластеру 2, о чём свидетельствует согласованность результатов кластерного и дискриминантного анализов.

2.8 Проверка значимости различий средних значений дискриминантной функции в двух группах

Для проверки статистической значимости различий между двумя группами использовался критерий λ Уилкса. Расчеты проведены для всех возможных пар кластеров. Результаты представлены в таблице «Wilks' Lambda» (рис. 5). Для кластера 1 и кластера 2 значение p-value составило 0,6539, что больше 0,05. Это означает, что различия не значимы. Регионы-лидеры и регионы-лидеры по раскрываемости коррупционных дел статистически не различаются по совокупности показателей.

Для кластера 1 и кластера 3 значение p-value = 0,0120 < 0,05, то есть различия значимы. Регионы-лидеры значительно отличаются от регионов с минимальной раскрываемостью коррупционных дел.

Для кластера 2 и кластера 3 значение p-value = 0,0002 < 0,05, следовательно, различия высоко значимы. Регионы-лидеры по раскрываемости коррупционных дел наиболее сильно отличаются от регионов с минимальной раскрываемостью коррупционных дел.

2.9 Оценка качества дискриминантного анализа

Качество дискриминантного анализа оценивалось на основе таблицы Eigenvalues (рис. 4). По результатам таблицы, первая дискриминантная функция объясняет 95,77% межгрупповой дисперсии, что свидетельствует о ее высокой информативности. Каноническая корреляция для первой функции составляет 0,6994, что указывает на сильную связь между дискриминантной функцией и кластерами. Вторая функция объясняет лишь 4,23% дисперсии и имеет слабую каноническую корреляцию (0,2015), поэтому ее вклад в разделение кластеров минимален.

Таким образом, дискриминантный анализ произведён качественно. Первая дискриминантная функция является основным инструментом разделения трех кластеров регионов.

2.10 Оценка целесообразности проведения дискриминантного анализа по исходным данным

Проведение дискриминантного анализа для данных регионов РФ является частично целесообразным. Анализируя таблицу Eigenvalues (рис. 4), первая дискриминантная функция объясняет 95,77% межгрупповой дисперсии, что свидетельствует о высокой информативности построенной модели. Каноническая корреляция составляет 0,6994, указывая на сильную связь между дискриминантной функцией и кластерами. Анализ попарных различий (см. таблицу Wilks' Lambda рис. 5) показал, что кластер 3 «Регионы с минимальной раскрываемостью коррупционных дел» статистически значимо отличается от кластера 1 «Регионы-лидеры» ($p\text{-value} = 0,012$) и кластера 2 «Регионы-лидеры по раскрываемости коррупционных дел» ($p\text{-value} = 0,0002$). Однако различия между кластерами 1 и 2 не являются значимыми ($p\text{-value} = 0,6539$). Доля верно классифицированных случаев (см. таблицу Summary Table рис. 3) составила лишь 52,17%. Особенно низкое качество классификации наблюдается для кластера 1 (26,67% верных попаданий).

Таким образом, дискриминантный анализ для исходных данных целесообразен лишь частично. Модель хорошо выделяет кластер 3, но не способна в должной степени различать кластеры 1 и 2.

3. Построение деревьев классификации

3.1 Выбор зависимой переменной – дискретная шкала

Для построения деревьев классификации в качестве зависимой переменной выступает переменная «Принадлежность к кластеру», полученная в результате кластеризации методом k-средних в предыдущей модульной работе. Данная переменная является дискретной, так как принимает только целые значения: 1, 2, 3. Выбор дискретной зависимой переменной обусловлен целью классификации - отнесение каждого региона к одному из трех заранее выделенных кластеров на основе показателей раскрываемости преступлений.

3.2 Построение деревьев с помощью метода CHAID (или CRT) с различными независимыми переменными

При помощи метода CRT с использованием критерия Джини на языке программирования Python нами были построены семь вариантов деревьев классификации с различными наборами независимых переменных: в первом варианте использовались все пять переменных (общая раскрываемость преступлений, раскрываемость тяжких преступлений, раскрываемость коррупционных дел, раскрываемость преступлений в сфере ИКТ, раскрываемость наркопреступлений), во втором варианте использовались три наиболее значимые для анализа переменные (общая раскрываемость, раскрываемость коррупционных дел, раскрываемость наркопреступлений), во всех последующих вариантах мы по очереди исключали каждую из переменных. Результаты построения представлены ниже.




Рисунок 9. Вариант построения №1 (используются все переменные)




Рисунок 10. Вариант построения №2 (используются три наиболее значимые переменные)




Рисунок 11. Вариант построения №3 (используются все переменные, кроме раскрываемости дел с использованием ИКТ)




Рисунок 12. Вариант построения №4 (используются все переменные, кроме раскрываемости тяжких преступлений)




Рисунок 13. Вариант построения №5 (используются все переменные, кроме раскрываемости наркопреступлений)




Рисунок 14. Вариант построения №6 (используются все переменные, кроме раскрываемости коррупционных дел)




Рисунок 15. Вариант построения №7 (используются все переменные, кроме общей раскрываемости)

3.3 Выбор оптимального дерева с помощью таблицы классификации

Для оценки качества построенных деревьев классификации использовалась таблица классификации, рассчитанная для каждого дерева с помощью Python. На первом этапе вся выборка была разделена на две части: обучающая выборка (70% данных, 48 регионов) использовалась для построения дерева классификации, тестовая выборка (30% данных, 21 регион) использовалась для оценки качества модели. Именно при таких пропорциях данных для обучения модели достаточно и тестовая выборка является репрезентативной, что обеспечивает высокую надёжность оценки. Для каждого региона из тестовой выборки обученное дерево классификации вычисляло предсказанный кластер на основе его показателей раскрываемости. Таким образом, таблица классификации представляет собой квадратную матрицу, в которой строки соответствуют фактическим кластерам регионов, а столбцы соответствуют предсказанным кластерам. Диагональные элементы матрицы показывают количество верно классифицированных регионов для каждого кластера, остальные элементы показывают количество ошибочно классифицированных регионов.

		Предсказанные кластеры		
	Вар. 1	Кластер 1	Кластер 2	Кластер 3
Фактич. кластеры	Кластер 1	0	6	3
	Кластер 2	3	5	0
	Кластер 3	2	1	1

Рисунок 16. Таблица классификации для варианта №1

		Предсказанные кластеры		
	Вар. 2	Кластер 1	Кластер 2	Кластер 3
Фактич. кластеры	Кластер 1	0	6	3
	Кластер 2	3	5	0
	Кластер 3	2	1	1

Рисунок 17. Таблица классификации для варианта №2

		Предсказанные кластеры		
	Вар. 3	Кластер 1	Кластер 2	Кластер 3
Фактич. кластеры	Кластер 1	1	6	2
	Кластер 2	3	5	0
	Кластер 3	2	1	1

Рисунок 18. Таблица классификации для варианта №3

		Предсказанные кластеры		
	Вар. 4	Кластер 1	Кластер 2	Кластер 3
Фактич. кластеры	Кластер 1	0	6	3
	Кластер 2	3	5	0
	Кластер 3	1	1	2

Рисунок 19. Таблица классификации для варианта №4

		Предсказанные кластеры		
	Вар. 5	Кластер 1	Кластер 2	Кластер 3
Фактич. кластеры	Кластер 1	6	2	1
	Кластер 2	4	4	0
	Кластер 3	2	1	1

Рисунок 20. Таблица классификации для варианта №5

		Предсказанные кластеры		
	Вар. 6	Кластер 1	Кластер 2	Кластер 3
Фактич. кластеры	Кластер 1	7	0	2
	Кластер 2	6	2	0
	Кластер 3	3	1	0

Рисунок 21. Таблица классификации для варианта №6

	Вар. 7	Предсказанные кластеры		
		Кластер 1	Кластер 2	Кластер 3
Фактич. кластеры	Кластер 1	5	3	1
	Кластер 2	7	1	0
	Кластер 3	2	1	1

Рисунок 22. Таблица классификации для варианта №7

Далее для каждой таблицы классификации рассчитываем общую точность классификации по формуле:

$$\text{общая точность классификации} = \frac{\text{количество верно классифицированных объектов}}{\text{общее количество объектов в тестовой выборке}} * 100\%,$$

где количество верно классифицированных объектов - это сумма диагональных элементов матрицы, общее количество объектов в тестовой выборке - это сумма всех элементов матрицы. Полученные результаты:

- Вариант №1 – общая точность классификации равна 28,57%
- Вариант №2 – общая точность классификации равна 28,57%
- Вариант №3 – общая точность классификации равна 33,33%
- Вариант №4 – общая точность классификации равна 33,33%
- Вариант №5 – общая точность классификации равна 52,38%
- Вариант №6 – общая точность классификации равна 42,86%
- Вариант №7 – общая точность классификации равна 33,33%

Таким образом, наибольшая общая точность классификации наблюдается у дерева с использованием всех переменных, кроме раскрываемости наркопреступлений (Вариант построения №5) - 52,38%, следовательно, это дерево классификации является оптимальным.

3.5 Интерпретация результатов.

Таким образом, нами были построены деревья классификации при помощи метода CRT с использованием критерия Джини для отнесения регионов РФ к одному из трех кластеров на основе показателей раскрываемости преступлений. Было построено 7 вариантов деревьев с различными наборами независимых переменных. Оптимальным признано дерево, построенное без переменной «Раскрываемость наркопреступлений», показавшее максимальную точность (52,38%).

	Вар. 5	Предсказанные кластеры			Верно
		Кластер 1	Кластер 2	Кластер 3	
Фактич. кластеры	Кластер 1	6	2	1	66,67%
	Кластер 2	4	4	0	50,00%
	Кластер 3	2	1	1	25,00%

Рисунок 23. Таблица классификации для варианта №5 с расчётом процента верно предсказанных регионов

Исходя из таблицы классификации для оптимального дерева, можно сделать следующие выводы:

- Кластер 1 распознается лучше всего (6 из 9, 67% верных предсказаний)
- Кластер 2 распознается удовлетворительно (4 из 8, 50% верных предсказаний)
- Кластер 3 распознается хуже всего (1 из 4, 25% верных предсказаний).

Краткие выводы, к которым мы пришли по результатам построения деревьев классификации:

- Максимальная точность классификации для оптимального дерева составила 52,38%, что выше случайного угадывания (33,3%)
- Наилучшее качество классификации достигнуто для кластера 1 (67% верных предсказаний), наихудшее - для кластера 3 (25%)
- Кластер 2 распознается удовлетворительно (50% верных предсказаний)
- Общая точность модели (52,38%) является приемлемой, но не высокой, что может быть связано с малым объемом выборки (69 регионов).

4. Декомпозиция смеси распределений

4.1 Общий анализ выборки

Исходная выборка содержит 1310 наблюдений.

Основные статистические характеристики:

- Диапазон данных: (0.04, 152.85)
- Среднее значение: 71.05
- Стандартное отклонение: 43.12

Большой разброс данных (стандартное отклонение сопоставимо со средним) указывает на то, что данные, представляют собой смесь нескольких распределений с различными параметрами.

4.2 Определение оптимального числа компонент смеси

Для определения оптимального количества компонент смеси использовался информационный критерий Байеса (BIC). Были построены и сравнены модели с 2, 3 и 4 компонентами.

Результаты сравнения моделей:

Число компонент	BIC	AIC
2	13028.74	13002.85
3	12897.33	12855.91
4	12669.99	12613.03

Вывод: Модель с 4 компонентами показала наименьшие значения BIC и AIC, что свидетельствует о наилучшем балансе между точностью подгонки и сложностью модели.




Рис. 24. Сравнение моделей с разным числом компонент (критерии BIC и AIC)

4.3 Параметры распределений

После применения алгоритма Gaussian Mixture Models (GMM) с 4 компонентами были получены следующие параметры распределений:

Распределение 1 (переходная зона)

- Среднее (μ_1): 55.41
- Стандартное отклонение (σ_1): 22.70
- Вес в смеси: 25.0%
- Количество наблюдений: 295 (22.5%)
- Интервал: 30–85

Распределение 2 (высокие значения)

- Среднее (μ_2): 131.80
- Стандартное отклонение (σ_2): 13.45
- Вес в смеси: 11.4%
- Количество наблюдений: 148 (11.3%)
- Интервал: 115–152

Распределение 3 (основная компонента)

- Среднее (μ_3): 100.04
- Стандартное отклонение (σ_3): 6.15
- Вес в смеси: 39.4%
- Количество наблюдений: 533 (40.7%)

- Интервал: 85–115

Распределение 4 (низкие значения)

- Среднее (μ_4): 11.31
- Стандартное отклонение (σ_4): 8.54
- Вес в смеси: 24.2%
- Количество наблюдений: 334 (25.5%)
- Интервал: 0–30





Рис. 25. Декомпозиция смеси распределений (4 компоненты)






Рис. 26. Гистограммы отдельных распределений с наложенными теоретическими кривыми нормального распределения

4.4 Интерпретация результатов

Анализ полученных распределений показывает четкую структуру данных:

1. Распределение 4 охватывает очень низкие значения (0–30) с центром около 11. Это может соответствовать одной группе процессов.
2. Распределение 1 представляет переходную зону (30–85) с большим разбросом ($\sigma=22.70$), что указывает на меньшую однородность данных в этом диапазоне.
3. Распределение 3 является доминирующей компонентой (39.4% всех данных) с узким пиком вокруг значения 100. Малое стандартное отклонение ($\sigma=6.15$) свидетельствует о высокой концентрации данных.
4. Распределение 2 описывает «хвост» распределения — самые высокие значения (115–152).

4.5 Классификация наблюдения №22

- Значение наблюдения: $X_{22} = 102.90$
- Вероятности принадлежности к распределениям:

- Распределение 1: 2.07%
- Распределение 2: 1.42%
- Распределение 3: 96.51%
- Распределение 4: 0.00%

Таким образом, наблюдение №22 с вероятностью 96.5% относится к Распределению 3 (основной компоненте с $\mu=100.04$, $\sigma=6.15$).

Вывод по результатам декомпозиции смеси распределений:

В ходе выполнения работы:

1. Проведена декомпозиция смеси распределений с использованием алгоритма GMM
2. Определено оптимальное количество компонент: 4 распределения (на основе критерия BIC)
3. Для каждого распределения найдены параметры: среднее, стандартное отклонение, вес в смеси
4. Выполнена визуализация результатов (общая гистограмма и отдельные распределения)
5. Наблюдение №22 ($X=102.90$) классифицировано и отнесено к Распределению 3 с уверенностью 96.5%

Общие выводы по результатам модульной работы:

Ключевым фактором, разделяющим регионы на кластеры, является раскрываемость коррупционных дел. Точность классификации оказалась невысокой (52,38%), что требует увеличения выборки или включения дополнительных переменных. Деревья решений обеспечивают более наглядную интерпретацию по сравнению с дискриминантным анализом.

Проверка ранее выдвинутых гипотез:

- Гипотеза H_1 подтвердилась. Выделены три четко интерпретируемых кластера, различающиеся по структуре раскрываемости.

- Гипотеза H_2 не подтвердилась. Общая точность дискриминантного анализа составила лишь 52,17%.
- Гипотеза H_3 подтвердилась. Деревья решений являются более наглядными и понятными для анализа.

Приложения

Приложение 1. Исходная выборка

1	Принадлежность к кластеру	Регион РФ	Общая раскрываемость, %	Раскрываемость тяжких преступлений, %	Раскрываемость коррупционных дел, %	Раскрываемость преступлений в сфере ИКТ, %	Раскрываемость наркопреступлений, %
2	1	Белгородская область	57,6	37,8	100	18,4	76,1
3	1	Брянская область	58,4	50,4	98,9	14,9	57,7
4	1	Владимирская область	51,2	35,4	96,5	14,9	46,7
5	1	Воронежская область	42,5	28	97,5	15,6	50,5
6	1	Ивановская область	51,5	43,1	98,6	21,3	51,4
7	1	Калужская область	50,5	37,5	82,3	20,5	66,9
8	1	Курская область	57,7	37,1	99,5	19,5	66,6
9	3	Московская область	63,5	53,7	95,2	30,3	56,8
10	1	Липецкая область	57,2	34,4	84,8	20,3	55,9
11	1	Орловская область	47,4	42	82,8	17,4	47,3
12	1	Рязанская область	59,3	54	89,7	22,2	58
13	1	Смоленская область	51,1	31,9	97,2	11,7	40,2
14	1	Тамбовская область	67	58,9	97,1	26	76,6
15	1	Тверская область	39,6	28,3	95,8	12,2	39,3
16	1	Тульская область	59,1	51,2	100	25,2	54,1
17	1	Ярославская область	48	37,5	99,1	19,6	52,8
18	1	Архангельская область	54,3	36,2	96,7	19,3	46,5
19	2	Ненецкий автономный округ	67	41,5	100	22,4	59,5
20	2	г. Санкт-Петербург	41,8	24,4	97,3	14,1	53,9
21	1	Вологодская область	56,3	47,4	96,6	18,5	56,6
22	1	Калининградская область	53,1	41,4	78,2	21,9	56,3
23	1	Новгородская область	47,3	33,4	99,3	21,7	55,1
24	1	Псковская область	62,9	39,9	93,3	33,4	79,1
25	1	Республика Карелия	50,6	33,7	97,3	16,8	61,5
26	2	Республика Кабардино-Балкарская Республика	68,3	53,8	96,3	23,4	70,3
27	2	Республика Ингушетия	59,3	46,6	82,2	33,1	75,3
28	2	Республика Северная Осетия - Алания	67,2	53,3	98	20,5	57,4
29	2	Ставропольский край	49,8	34,2	94,2	17,5	54,7
30	2	Астраханская область	62,9	43,7	99,1	26,9	72,2
31	2	Волгоградская область	43,9	30,1	94,1	12,3	59
32	2	г. Севастополь	46,3	45,4	95,7	11,3	42,7
33	2	Ростовская область	45,6	40,4	97,1	15,6	53,3
34	2	Краснодарский край	47,4	42,8	96,7	14,4	74,8
35	2	Республика Крым	61,6	46,1	97,6	17,3	63,2
36	1	Кировская область	56,2	30,7	97,8	15,4	46,2
37	1	Нижегородская область	52,1	40,8	96,9	24,4	57,1
38	1	Оренбургская область	62,7	43,7	97,4	36	77,4
39	1	Пензенская область	61,3	34	98,9	21,6	52,3
40	2	Пермский край	54,9	41,2	98	25,8	60,4

	Принадлежность к кластеру	Регион РФ	Общая раскрываемость, %	Раскрываемость тяжких преступлений, %	Раскрываемость коррупционных дел, %	Раскрываемость преступлений в сфере ИКТ, %	Раскрываемость наркотикопреступлений, %
1							
41		2 Республика Татарстан	48,1	33,2	96,1	18,4	41,7
42		2 Республика Башкортостан	51,2	32,8	97,6	15,5	38,6
43		2 Республика Марий Эл	53,8	34,4	98,2	19,4	42,3
44		2 Республика Мордовия	68,2	47,4	100	36,3	73,9
45		2 Самарская область	57,2	45,1	98,5	28,6	73,2
46		1 Саратовская область	48,6	37,6	94,4	17,2	43,5
47		2 Удмуртская Республика	49,8	31,7	98,8	20,1	39
48		1 Ульяновская область	63,2	47,9	97,3	23	57
49		1 Чувашская Республика	61	32,7	94,1	32,6	75,7
50		1 Курганская область	63,9	49,5	100	31,3	72,3
51		2 Свердловская область	56,9	55	95,5	25,2	53,6
52		2 Тюменская область	54,3	35,5	98,1	20,5	46,6
53		2 Ханты-Мансийский автономный округ - Югра	51,9	36,2	96,5	20,9	45,7
54		2 Челябинская область	53,3	45,1	99,2	27,7	56,1
55		3 Алтайский край	57,1	38,5	98,5	16,1	61,2
56		3 Иркутская область	53,1	33,5	87,8	18,9	61,9
57		3 Кемеровская область - Кузбасс	55	39,9	79,1	25,5	46,1
58		3 Красноярский край	54,1	42,5	87,5	21,4	56,9
59		3 Новосибирская область	36,8	25,8	75	11,7	44,4
60		3 Омская область	59,1	40,1	86,1	16,4	55,4
61		1 Республика Алтай	74,2	64,3	94,8	30,3	83,3
62		3 Республика Тыва	49,6	47,7	85,7	16,5	76,6
63		3 Республика Хакасия	63	45,5	97,2	19,6	62,9
64		2 Томская область	58,3	43,9	99	28,1	49,1
65		2 Амурская область	42,7	32,9	100	12,7	65,6
66		3 Еврейская автономная область	41	33	79,4	15,4	66,6
67		3 Забайкальский край	57,7	59,4	98,4	22,7	80,6
68		3 Камчатский край	62,7	48,7	80,2	25	65,2
69		2 Магаданская область	56,1	40,2	90	20,8	46,9
70		2 Приморский край	48,3	34,9	98,5	16,5	52,8
71		3 Республика Саха (Якутия)	72	61	85,7	34,8	69,3
72		2 Сахалинская область	54,5	39,5	98,5	30,2	52
73		2 Хабаровский край	51,8	38,8	99	20,8	57,7

Приложение 2. Таблица Categorization of Training Data

Categorization of Training Data			
1	2	3	category
0,5208207	0,38195881	0,09722049	1
0,36181161	0,45655552	0,18163287	2
0,4326432	0,48565073	0,08170607	2
0,37841275	0,59558802	0,02599923	2
0,29210295	0,67636871	0,03152834	2
0,07571417	0,034965	0,88932084	3
0,50355735	0,42959271	0,06684994	1
0,18364443	0,06548432	0,75087125	3
0,08918171	0,07662337	0,83419492	3
0,16644044	0,17986808	0,65369149	3
0,47697696	0,45737471	0,06564833	1
0,30688864	0,3533419	0,33976946	2
0,34960052	0,61454772	0,03585177	2
0,27703118	0,69046428	0,03250455	2
0,31084496	0,6669131	0,02224194	2
0,42877331	0,51616695	0,05505974	2
0,3533797	0,47978433	0,16683597	2
0,03027992	0,01342688	0,95629319	3
0,32230645	0,66393676	0,0137568	2
0,4764151	0,35306723	0,17051768	1
0,46240641	0,45653279	0,0810608	1
0,54655894	0,39761081	0,05583025	1
0,32868807	0,6287764	0,04253552	2
0,53656715	0,42606616	0,03736669	1
0,40991646	0,46330421	0,12677933	2
0,5482148	0,36498111	0,08680409	1
0,35887114	0,60028245	0,04084641	2
0,39950149	0,55779988	0,04269863	2
0,35789352	0,55021236	0,09189412	2
0,20698625	0,17322296	0,61979079	3
0,54025134	0,39456818	0,06518047	1
0,42912161	0,33866642	0,23221197	1
0,33854395	0,41732857	0,24412748	2
0,45754367	0,47369105	0,06876528	2
0,43590287	0,38841848	0,17567865	1
0,30970346	0,6213665	0,06893004	2

0,08453781	0,05271404	0,86274815	3
0,35150424	0,27089491	0,37760085	3
0,39406416	0,3859979	0,21993794	1
0,43172	0,4344069	0,1338731	2
0,36698268	0,59788749	0,03512983	2
0,40871727	0,56542963	0,0258531	2
0,39953465	0,57302108	0,02744428	2
0,3500333	0,61412425	0,03584246	2
0,35119243	0,59881575	0,04999181	2
0,24808146	0,62975332	0,12216522	2
0,40921062	0,56087341	0,02991597	2
0,37591036	0,58514583	0,03894381	2
0,24474541	0,73928146	0,01597314	2
0,29926304	0,68401142	0,01672554	2
0,2791487	0,5718454	0,1490059	2
0,38253003	0,57532692	0,04214305	2
0,35120917	0,29976068	0,34903015	1
0,3816033	0,58063899	0,03775772	2
0,2791508	0,71056379	0,01028541	2
0,35956217	0,60684961	0,03358822	2
0,31101432	0,57021003	0,11877565	2
0,0473318	0,03130039	0,92136782	3
0,44684393	0,3444194	0,20873667	1
0,49136062	0,39611763	0,11252175	1
0,2542849	0,49487455	0,25084054	2
0,21407111	0,17015716	0,61577173	3
0,2803203	0,13235084	0,58732886	3
0,07748499	0,0433704	0,87914461	3
0,03041851	0,01234695	0,95723454	3
0,12314945	0,04393273	0,83291781	3
0,03836602	0,01785276	0,94378121	3
0,02476699	0,00888498	0,96634803	3
0,0803181	0,0588709	0,860811	3